SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

Interakcija čovjeka i robota

Zadatak 1

Mentori:

Student:

Krešimir Hartl

Zagreb, 2025.

SADRŽAJ

SADRŽAJ I
1. UVOD 1
2. Eksperimentalno snimanje 2
2.1. Komunikacija i prikupljanje podataka 2
2.2. Protokol snimanja 2
3. Obrada podataka 3
3.1. Pretprocesiranje 3
3.2. Izračun značajki 3
3.3. Struktura podataka 4
4. Klasifikacija - Linear Discriminant Analysis (LDA) 6
4.1. Opis klasifikatora 6
4.2. Trening 6
5. Validacija 8
5.1. Accuracy 8
5.2. Precision & Recall 8
5.3. F1-score 8
5.4. The Matthews correlation coefficient MCC 9
6. Pregled validacije 11
7. ZAKLJUČAK 12
LITERATURA 13

1. UVOD

U okviru ovog zadatka provedena je analiza klasifikacije pokreta kolaborativnih robota u kategorije "brzo" i "sporo" pomoću objektivnih mjerenja brzine i sile. Cilj istraživanja bio je kvantitativno opisati subjektivnu percepciju brzine pokreta robota te razviti klasifikacijski model koji može automatski razlikovati brze i spore kretnje na temelju izmjerenih podataka. Takva klasifikacija omogućava bolje razumijevanje interakcije čovjeka i robota u suradničkom okruženju te optimizaciju ponašanja robota za sigurniju i ugodniju suradnju.

Pokusi su provedeni na Universal Robots kolaborativnim robotima, pri čemu su prikupljeni podaci o poziciji izvršnog člana i komponentama sile tijekom ručnog vođenja robota. Prikupljeni podaci poslužili su za treniranje i validaciju Linear Discriminant Analysis (LDA) klasifikatora.

2. EKSPERIMENTALNO SNIMANJE

2.1. Komunikacija i prikupljanje podataka

Komunikacija između robota i računala uspostavljena je pomoću TCP/IP protokola preko Ethernet LAN kabela. Robot je konfiguriran kao TCP klijent koji šalje podatke u realnom vremenu, dok je računalo postavljeno kao TCP server koji prima i pohranjuje te podatke. Računalo je konfigurirano sa statičkom IP adresom na određenom portu, omogućujući stabilnu mrežnu vezu između robota i računala.

Svako mjerenje sadržavalo je informacije o trenutnoj poziciji vrha alata robota (TCP) u kartezijevim koordinatama $((x),(y),(z))$ te komponente sile koje su djelovale na alat $\big((f_x),(f_y),(f_z)\big)$. Podaci su snimani frekvencijom od 100 Hz (svakih 0.01 sekunde) i spremani u CSV format za naknadnu analizu.

2.2. Protokol snimanja

Svaki par studenata snimio je 20 kretnji: 10 brzih i 10 sporih. Pokret je izveden ručnim vođenjem robota u kolaborativnom režimu rada, pri čemu je robot bio postavljen u način rada prilagođen vanjskim silama. Kretnje su snimane tako da simuliraju prirodne i prepoznatljive brzine koje čovjek percipira kao brze ili spore.

Dataset korišten za treniranje klasifikatora bio je "norsic", dok su ostali parovi (akrap_gugo, cuk_pongracic) korišteni isključivo za validaciju modela na nezavisnim podacima.

3. OBRADA PODATAKA

3.1. Pretprocesiranje

Sirovi podaci sadržavali su segmente koji nisu relevantni za klasifikaciju. U fazi pretprocesiranja primijenjeni su sljedeći postupci:

- Uklanjanje stacionarnih segmenata: Eliminirani su dijelovi snimki u kojima je brzina gibanja robota bila nula ili vrlo blizu nule. Ovi segmenti predstavljaju početak i kraj snimanja kada robot miruje.

3.2. Izračun značajki

Za svako snimanje izračunate su dvije ključne značajke:

Prosječna brzina:

Brzina je izračunata kao euklidska udaljenost između uzastopnih pozicija podijeljena s vremenskim korakom:

$$v_i = \frac{\left\{\sqrt{\left\{\left(x_{\{i+1\}} - x_i\right)^2 + \left(y_{\{i+1\}} - y_i\right)^2 + \left(z_{\{i+1\}} - z_i\right)^2\right\}}\right\}}{\Delta t}$$

gdje je Δt izračunata kao razlika između vremenskih trenutaka snimanja . Prosječna brzina ($\bar{v}$) izračunata je kao aritmetička sredina svih brzina unutar jedne snimke nakon uklanjanja irelevantnih segmenata.

Prosječna sila:

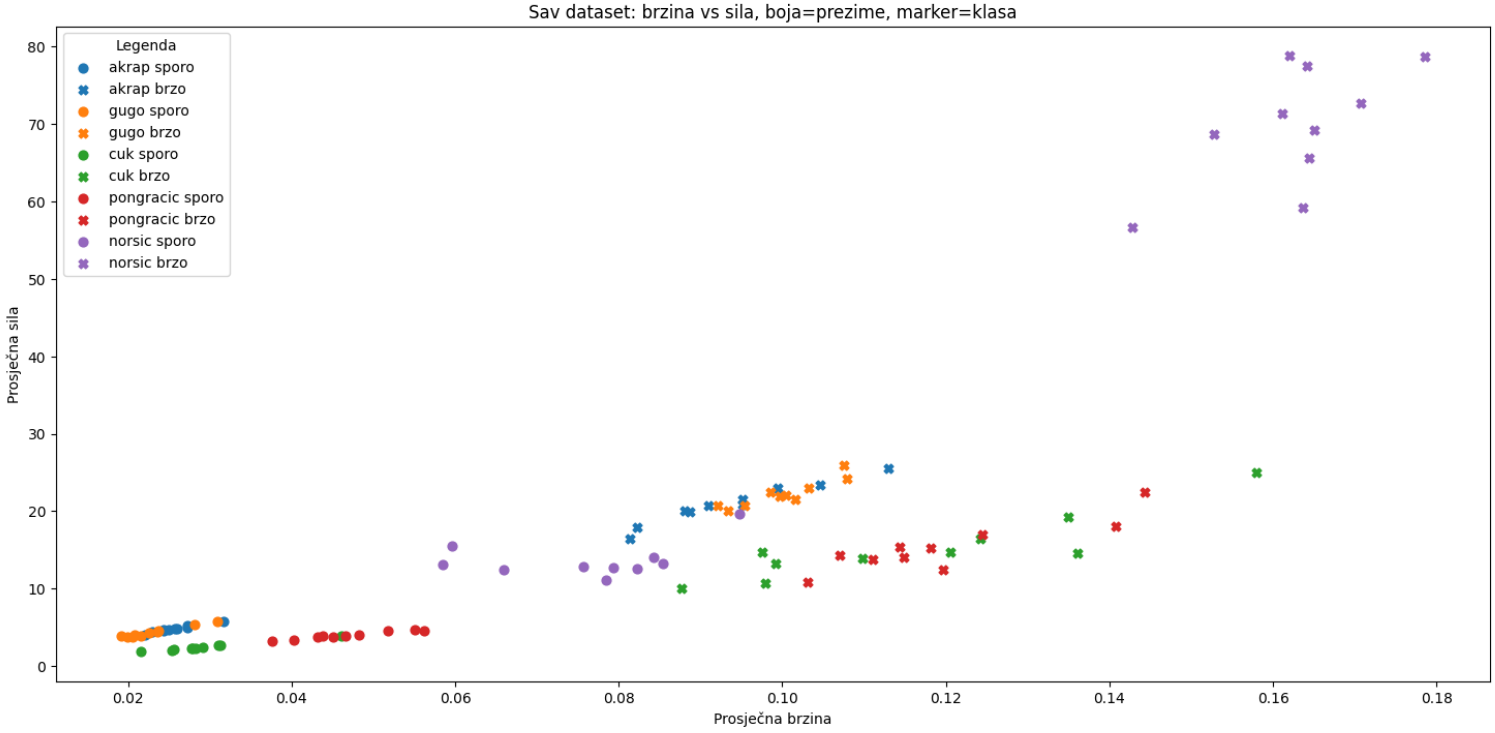
Sila je prikazana kao magnituda (norma) vektora sile:

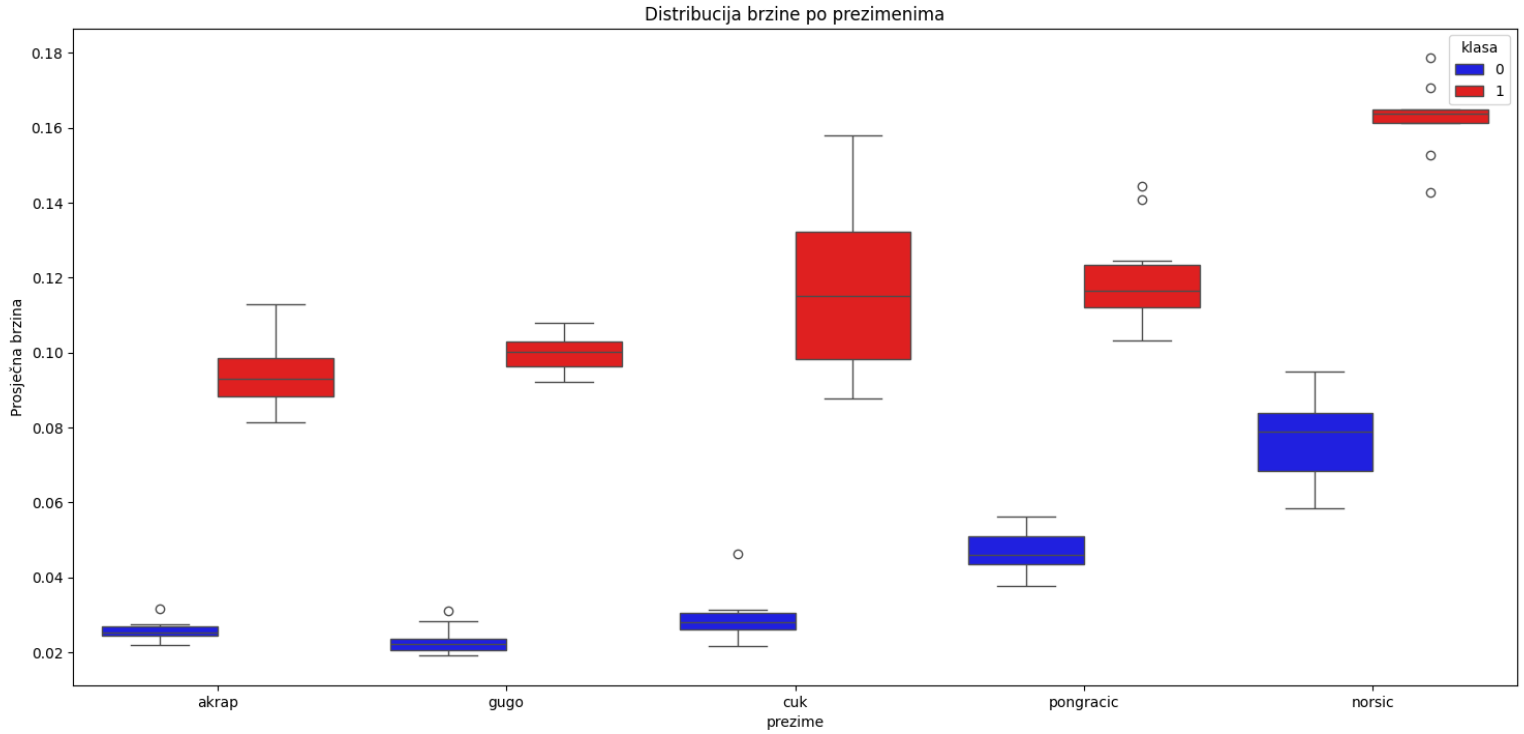
$$F_i = \sqrt{f_{x,i}^2 + f_{y,i}^2 + f_{z,i}^2}$$

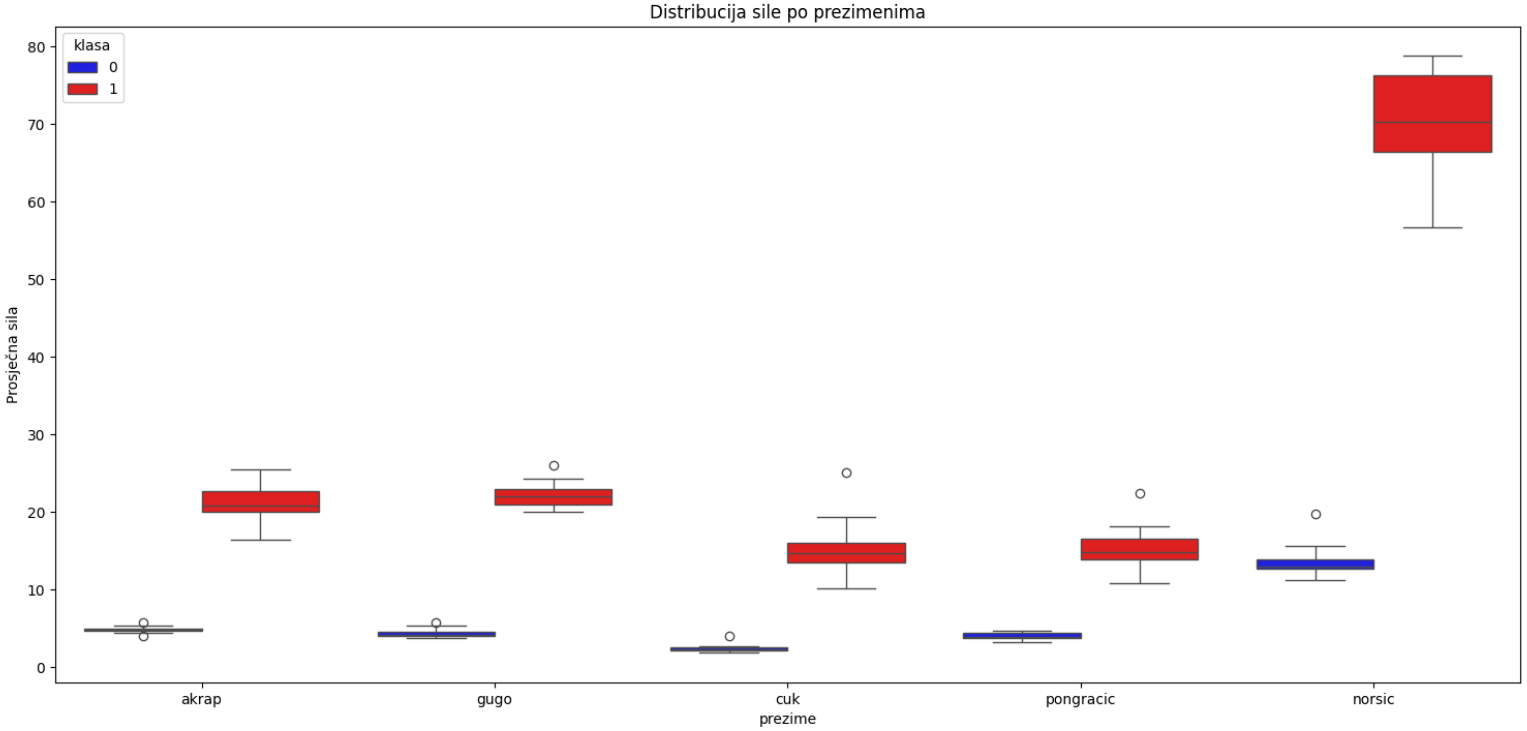
Prosječna sila ($\bar{F}$) izračunata je kao aritmetička sredina svih magnitud sile unutar jedne snimke.

3.3. Struktura podataka

Obrađeni podaci organizirani su kao set značajki $((\bar{v}),(\bar{F}))$ s pripadajućom oznakom klase (brzo = 1, sporo = 0). Ovakva struktura omogućava direktnu primjenu klasifikacijskih algoritama strojnog učenja.




Distribucija brzine po prezimenima
Prosječna brzina
0.18
0.16
0.14
0.12
0.10
0.08
0.06
0.04
0.02
klasa
0
1
akrap
gugo
cuk
pongracic
norsic
prezime


Distribucija sile po prezimenima
Prosječna sila
80
70
60
50
40
30
20
10
0
klasa
0
1
akrap
gugo
cuk
pongracic
norsic
prezime

4. KLASIFIKACIJA - LINEAR DISCRIMINANT ANALYSIS (LDA)

4.1. Opis klasifikatora

Linear Discriminant Analysis (LDA) je supervised klasifikacijski algoritam koji pronalazi linearnu granicu između klasa maksimalizirajući razmak između njihovih centara, a minimalizirajući varijabilnost unutar svake klase. LDA pretpostavlja da su klase raspoređene prema normalnoj distribuciji i da imaju slične kovarijance.Matematički, LDA traži projekciju podataka na nižu dimenzionalnost (u binarnoj klasifikaciji na jednu dimenziju) koja najbolje razdvaja klase. Granica odlučivanja definirana je kao:

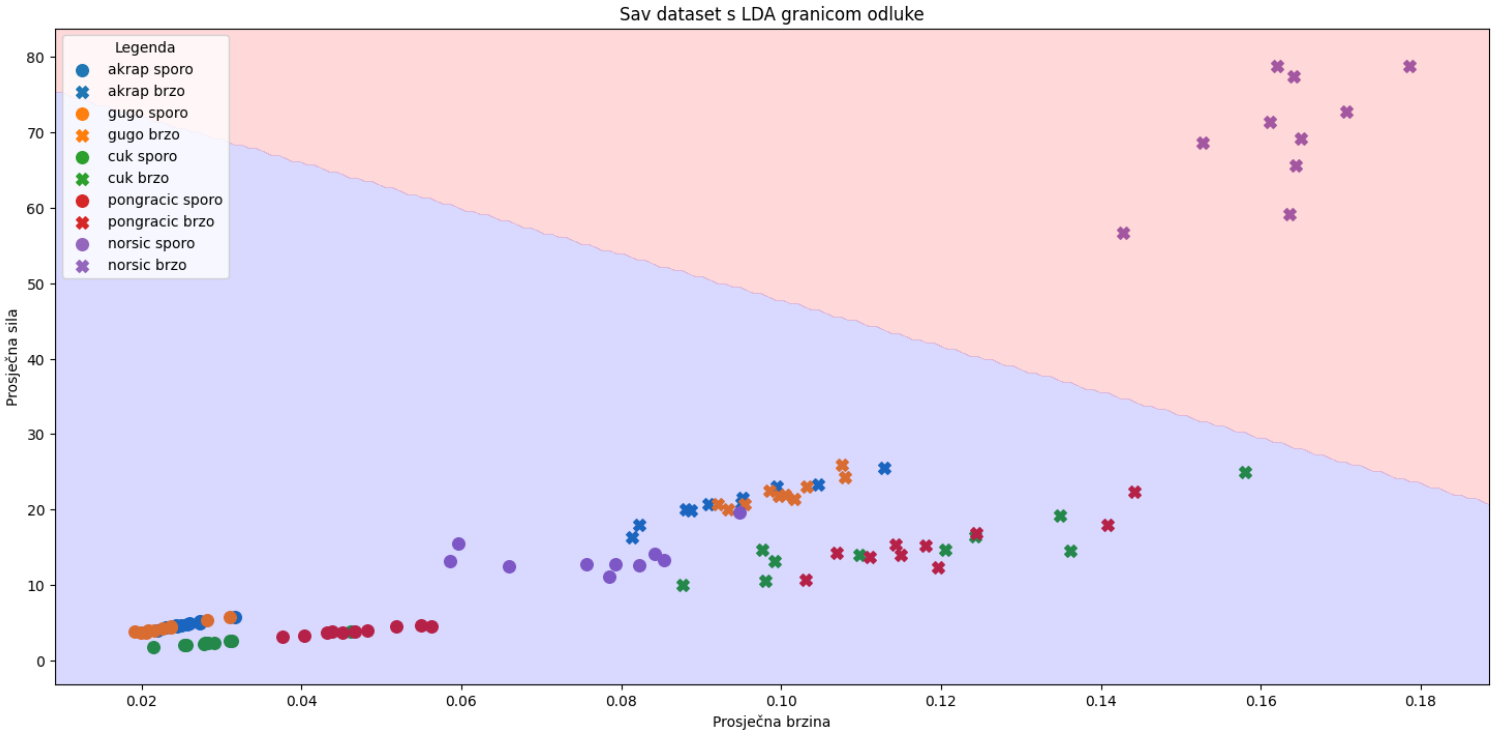
$$w^T x + b = 0$$

gdje je (w) vektor težina, (x) vektor značajki, a (b) prag. LDA je osobito pogodan za probleme s dvije klase i malim brojem značajki, kao što je slučaj u ovom zadatku.

4.2. Trening

Klasifikator je treniran isključivo na skupu podataka "norsic", koji je sadržavao 20 mjerenja (10 brzih i 10 sporih). Cijeli "norsic" dataset korišten za trening, a validacija je provedena na potpuno nezavisnim skupovima drugih studenata.

Ovakav pristup donosi prednosti u smislu bolje iskorištenosti podataka za treniranje, ali postavlja strože uvjete za validaciju, budući da se model testira na podacima iz različitih izvora koji mogu imati drukčije distribucije.


Sav dataset s LDA granicom odluke
Legenda
akrap sporo
akrap brzo
gugo sporo
gugo brzo
cuk sporo
cuk brzo
pongracic sporo
pongracic brzo
norsic sporo
norsic brzo
Prosječna sila
Prosječna brzina
0
10
20
30
40
50
60
70
80
0.02
0.04
0.06
0.08
0.10
0.12
0.14
0.16
0.18

5. VALIDACIJA

5.1. Accuracy

Accuracy mjeri globalnu točnost bez razlikovanja između tipova grešaka. Formula je:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Kod nebalansiranih podataka, accuracy može biti visoka čak i kad model uopće ne prepoznaje manjinsku klasu. Najbolje ga je koristiti samo kod balansiranih skupova podataka gdje su obje klase podjednako važne i podjednako zastupljene.

5.2. Precision & Recall

Precision mjeri kvalitetu pozitivnih predikcija. Formula je:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Visok precision znači da model rijetko pravi lažne alarme. Ključan je u scenarijima gdje je cijena false positive visoka.

Recall (poznat i kao sensitivity ili true positive rate) mjeri kompletnost detekcije. Formula je:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Visok recall znači da model rijetko propušta pozitivne slučajeve. Ključan je u scenarijima gdje je cijena false negative visoka.

5.3. F1-score

F1 score je harmonijska sredina precision i recall. Formula je:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

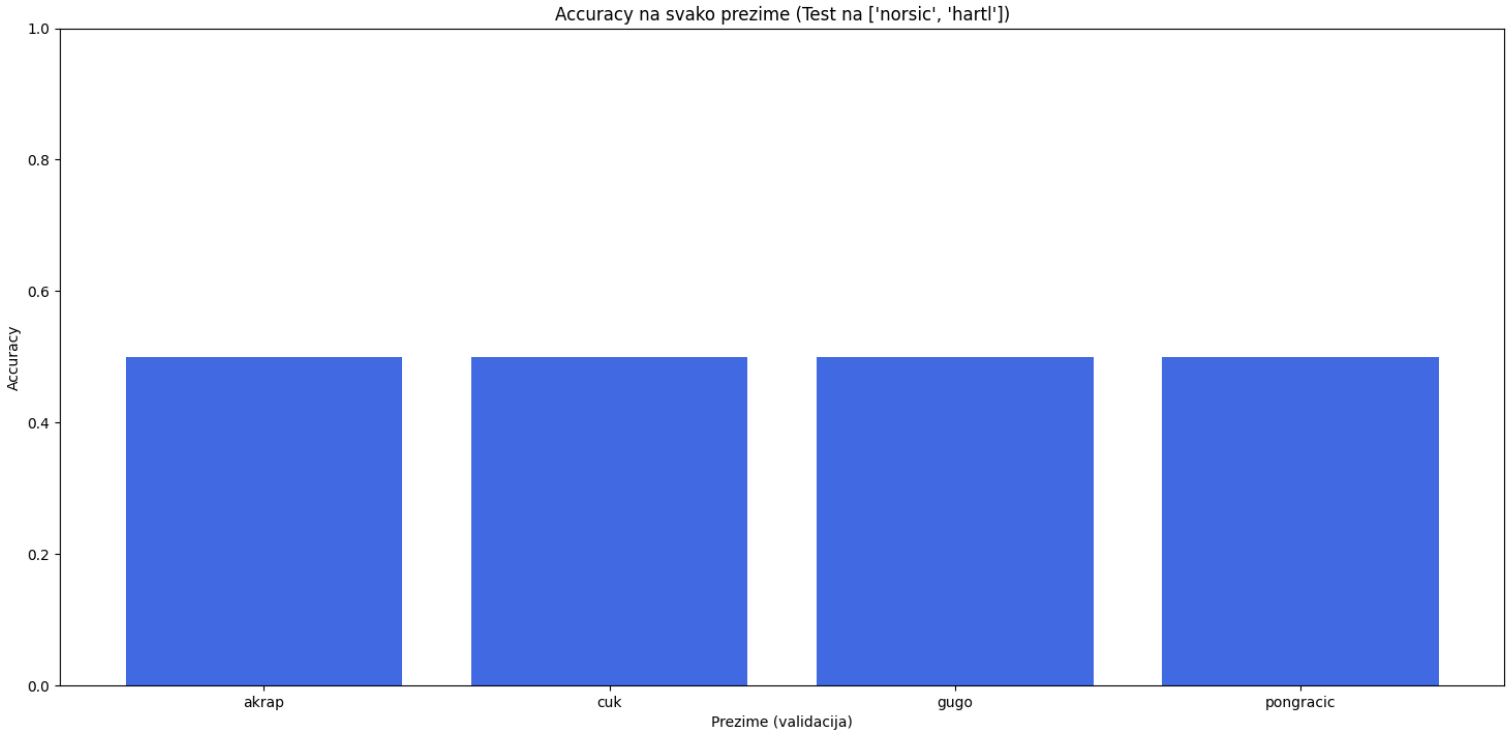
Harmonijska sredina jače kažnjava velike razlike između vrijednosti. F1 score prisiljava balans – model s savršenim precision ali niskim recall (ili obrnuto) nije dobar klasifikator.

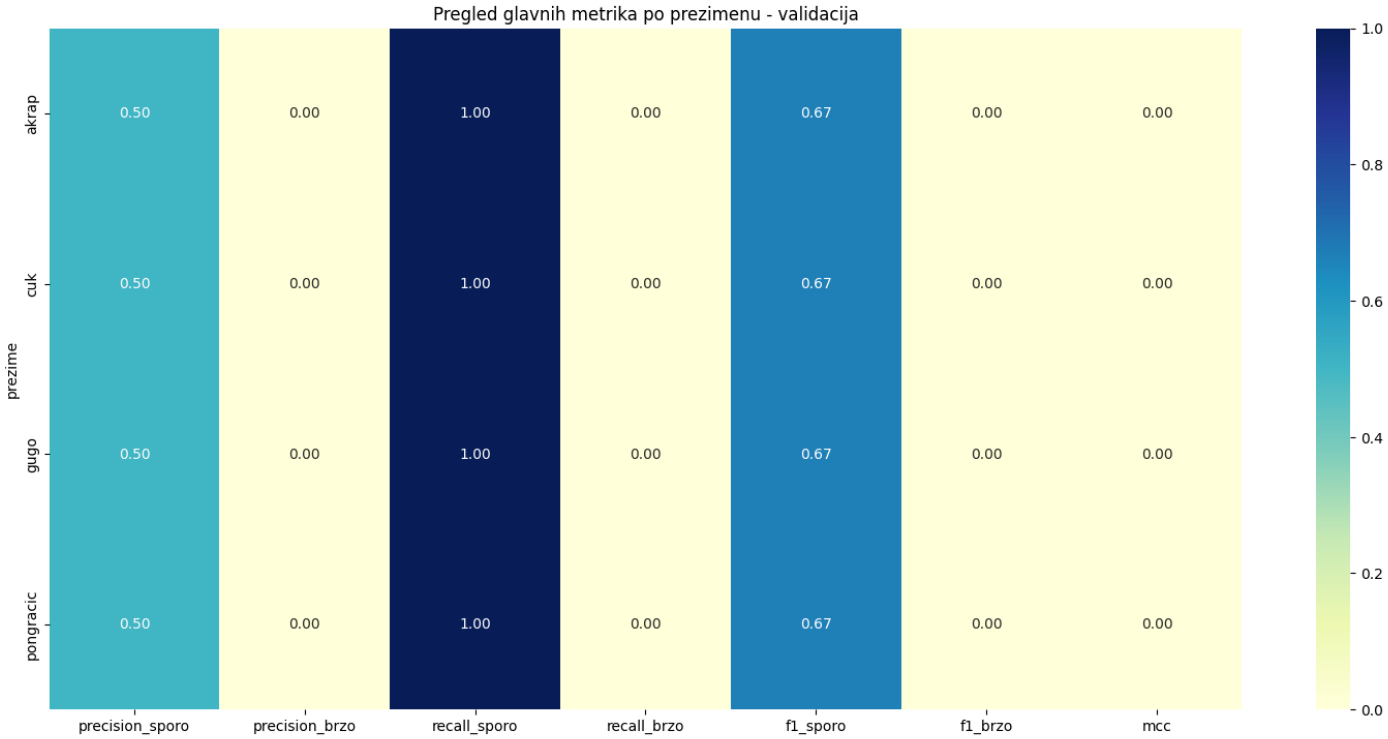
5.4. The Matthews correlation coefficient MCC

Matthews correlation coefficient (MCC) je jedina statistička mjera koja generira visok rezultat samo ako su vrijednosti svih četiriju osnovnih mjera (sensitivity, specificity, precision, negative predictive value) visoke. Formula je:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

MCC se kreće između -1 (potpuno kriva predikcija) i +1 (potpuno točna predikcija), gdje 0 znači da predikcija nije bolja od nasumičnog pogađanja. MCC je informativniji i pouzdaniji od accuracy i F1 score jer uzima u obzir omjer pozitivnih i negativnih instanci, kao i pozitivnih i negativnih predikcija.




Pregled glavnih metrika po prezimenu - validacija
prezime
akrap
cuk
gugo
pongracic
0.50 0.00 1.00 0.00 0.67 0.00 0.00
0.50 0.00 1.00 0.00 0.67 0.00 0.00
0.50 0.00 1.00 0.00 0.67 0.00 0.00
0.50 0.00 1.00 0.00 0.67 0.00 0.00
precision_sporo
precision_brzo
recall_sporo
recall_brzo
f1_sporo
f1_brzo
mcc
1.0
0.8
0.6
0.4
0.2
0.0

6. PREGLED VALIDACIJE

Klasifikator je treniran isključivo na podacima prikupljenima tijekom eksperimentalnog snimanja kod sudionika Noršić, što čini trening skup specifičnim i jedinstvenim. Za potrebe validacije korišteni su podaci drugih sudionika: Akrap, Gugo, Ćuk i Pongračić. Ova podjela omogućava ispitivanje sposobnosti modela da generalizira naučene obrasce na nove, neviđene podatke.

Međutim, primjetna je značajna razlika između distribucije podataka u trening i validacijskim skupovima. Takva razlika proizlazi iz individualnih varijacija u pokretima, sile i brzine koje karakteriziraju svakog sudionika, ali i tehničkih uvjeta snimanja. Zbog toga nisu zadovoljena ključna svojstva za dobro generalizirajući model, poput homogenosti i sličnosti skupova podataka.

Posljedično, performanse klasifikatora na validacijskim skupovima su znatno lošije u usporedbi s rezultatima postignutima na trening podacima. Ovakva slabija točnost odražava ograničenu sposobnost modela da pouzdano razlikuje brze i spore pokrete izvan uvjeta za koje je treniran. Time se naglašava važnost korištenja raznovrsnijih i reprezentativnijih skupova za treniranje kako bi se povećala robusnost i primjenjivost modela u različitim scenarijima.

7. ZAKLJUČAK

Model temeljen na Linear Discriminant Analysis pokazao se učinkovitim za klasifikaciju brzih i sporih kretnji robota na homogenim podacima. Ipak, generalizacija na različite uvjete snimanja i robotske sustave ograničena je zbog oslanjanja na apsolutne vrijednosti brzine i sile, koje variraju među različitim robotima i uvjetima.

Za razvoj robusnog i univerzalnog klasifikatora potrebno je:

- Proširiti trening skup na podatke iz više robota i uvjeta snimanja
- Razmotriti normalizaciju značajki po tipu robota ili kretnje
- Uvesti relacijske značajke koje su manje ovisne o fizičkim karakteristikama konkretnog robota
- Koristiti naprednije klasifikacijske algoritme (npr. SVM, Random Forest, neuronske mreže)

Rezultati ovog istraživanja pružaju temelje za daljnje proučavanje interakcije čovjeka i robota te razvoj sustava koji mogu autonomno prilagođavati brzinu pokreta robota na temelju konteksta i preferencija korisnika.

LITERATURA

[1] Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics*, *21*(1), 6. https://doi.org/10.1186/s12864-019-6413-7

[2] Daydulo, Y. D., Thamineni, B. L., & Dawud, A. A. (2023). Cardiac arrhythmia detection using deep learning approach and time frequency representation of ECG signals. *BMC Medical Informatics and Decision Making*, *23*(1), 232. https://doi.org/10.1186/s12911-023-02326-w

[3] Knežević, T. (2025). *01 Mjerenje i klasifikacija - Interakcija čovjeka i robota*. Fakultet strojarstva i brodogradnje, Sveučilište u Zagrebu.

[4] Knežević, T. (2025). *Ručno vođenje robota i prikupljanje podataka o pokretu - Vježbe UR5*. Fakultet strojarstva i brodogradnje, Sveučilište u Zagrebu.