SVEUČILIŠTE U ZAGREBU
FAKULTET STROJARSTVA I BRODOGRADNJE

Interakcija čovjeka i robota

ZADATAK 2

Krešimir Hartl

Zagreb, 2026.

SADRŽAJ

SADRŽAJ I
POPIS SLIKA I
POPIS TABLICA I
1. Body pose estimation 2
1.1. Usporedba ključnih točaka (MediaPipe vs. PennAction) 2
1.2. Izračun kuta zglobova 3
1.3. Nagib tijela 4
2. Head pose estimation 5
2.1. Vizualna interpretacija BIWI Head Pose podataka 5
2.2. Klasifikacija smjera pogleda 7
2.3. MediaPipe vs. BIWI: Usporedba orijentacije glave 9
3. Gesture recognition 11
3.1. Gesture Recognition demo 11
3.2. Ručno definirana pravila za nove geste 14
3.3. Klasifikator (ML) za dvije nove geste 16
PRILOZI 17

POPIS SLIKA

Slika 1. Usporedba ground truth i MediaPipe 2
Slika 2. Kutevi zglobova 3
Slika 3. Nagib tijela 4
Slika 4. Interpretacija BIWI Head Pose podataka Frame 50 5
Slika 5. Interpretacija BIWI Head Pose podataka Frame 350 6
Slika 6. Interpretacija BIWI Head Pose podataka Frame 508 6
Slika 7. Klasifikacija smjera pogleda Frame 50 7
Slika 8. Klasifikacija smjera pogleda Frame 350 8
Slika 9. Klasifikacija smjera pogleda Frame 508 8
Slika 10. Usporedba orijentacije glave Frame 50 9
Slika 11. Usporedba orijentacije glave Frame 350 10
Slika 12. Usporedba orijentacije glave Frame 508 10
Slika 13. Gesture Recognition demo Thumb up 11
Slika 14. Gesture Recognition demo Thumb down 12
Slika 15. Gesture Recognition demo Pointing up 12
Slika 16. Gesture Recognition demo Closed Fist 13
Slika 17. Gesture Recognition demo Open Palm 13
Slika 18. Gesta OK 14
Slika 19. Gesta PEACE 15
Slika 20. Klasifikator gesta THUMBS UP 16
Slika 21. Klasifikator gesta THUMBS DOWN 16

POPIS TABLICA

Tablica 1. Usporedba ključnih točaka ground truth i MediaPipe 2
Tablica 2. Kutevi zglobova 3
Tablica 3. Nagib tijela 4
Tablica 4. Interpretacija BIWI Head Pose podataka. 5
Tablica 5. Klasifikacija smjera pogleda 7
Tablica 6. MediaPipe vs. BIWI: Usporedba orijentacije glave 9

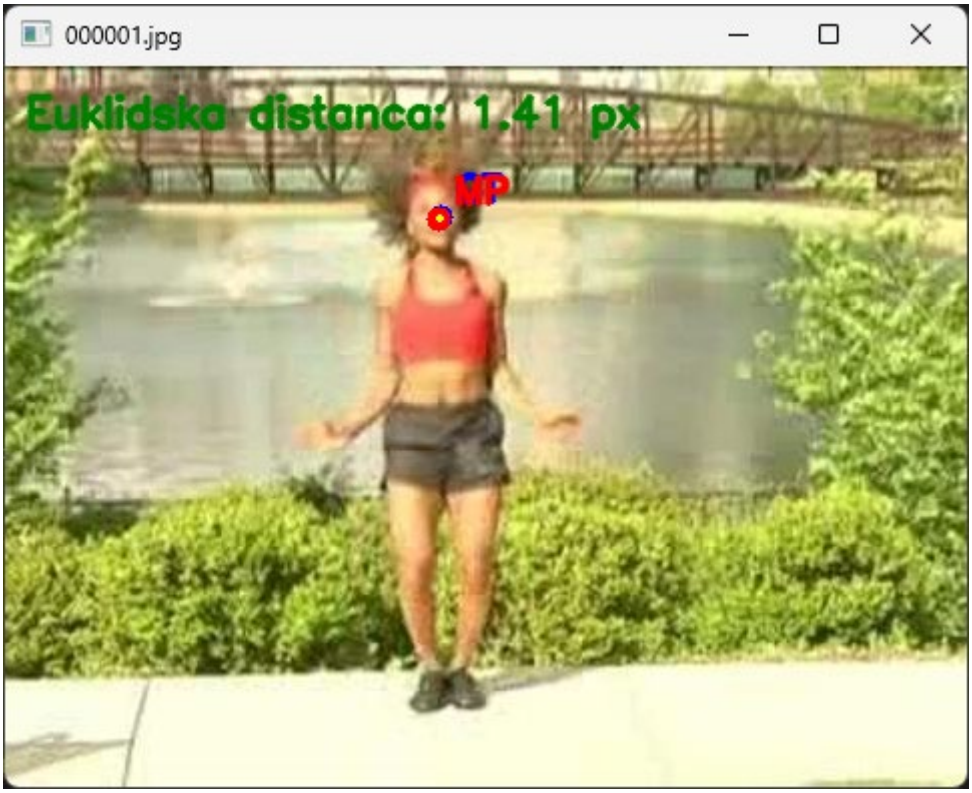
1. BODY POSE ESTIMATION

1.1. Usporedba ključnih točaka (MediaPipe vs. PennAction)

Odabrana ključna točka iz *PennAction* je „HEAD“ uspoređuje se s „NOSE“ iz *MediaPipe.*

Tablica 1. Usporedba ključnih točaka ground truth i MediaPipe

ID Slike	*Ground truth* (x, y)	*MediaPipe* (x, y)	Razlika
000001	217, 75	216, 76	1.41
000005	216, 63	217, 64	1.41
000010	214, 54	219, 48	7.81
000015	214, 63	214, 76	13
000020	216, 79	215, 72	7.07



Slika 1. Usporedba ground truth i MediaPipe

1.2. Izračun kuta zglobova

Tablica 2. Kutevi zglobova

ID Slike	Lakat (°)	Koljeno (°)
000001	145.74	171.14
000005	113.63	172.75
000010	90.3	179.18
000015	103.93	175.42
000020	113.33	176.23



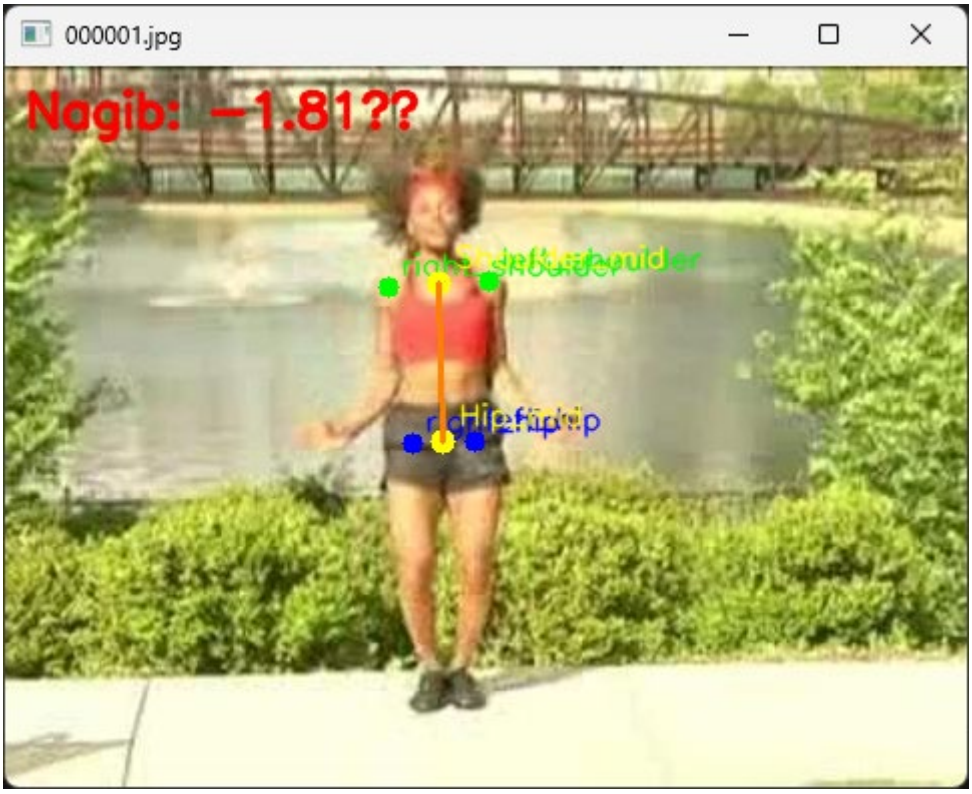
Slika 2. Kutevi zglobova

1.3. Nagib tijela

Odabrane su točke „LEFT_SHOULDER“ i „RIGHT_SHOULDER“ iz kojih se izračunava središte gornjeg dijela torza. Središte donjeg dijela tora izračunava se preko „LEFT_HIP“ i „RIGHT_HIP“

Tablica 3. Nagib tijela

ID Slike	Nagib (°)
000001	-1.81
000005	-1.14
000010	-3.53
000015	-1.61
000020	-1.31



Slika 3. Nagib tijela

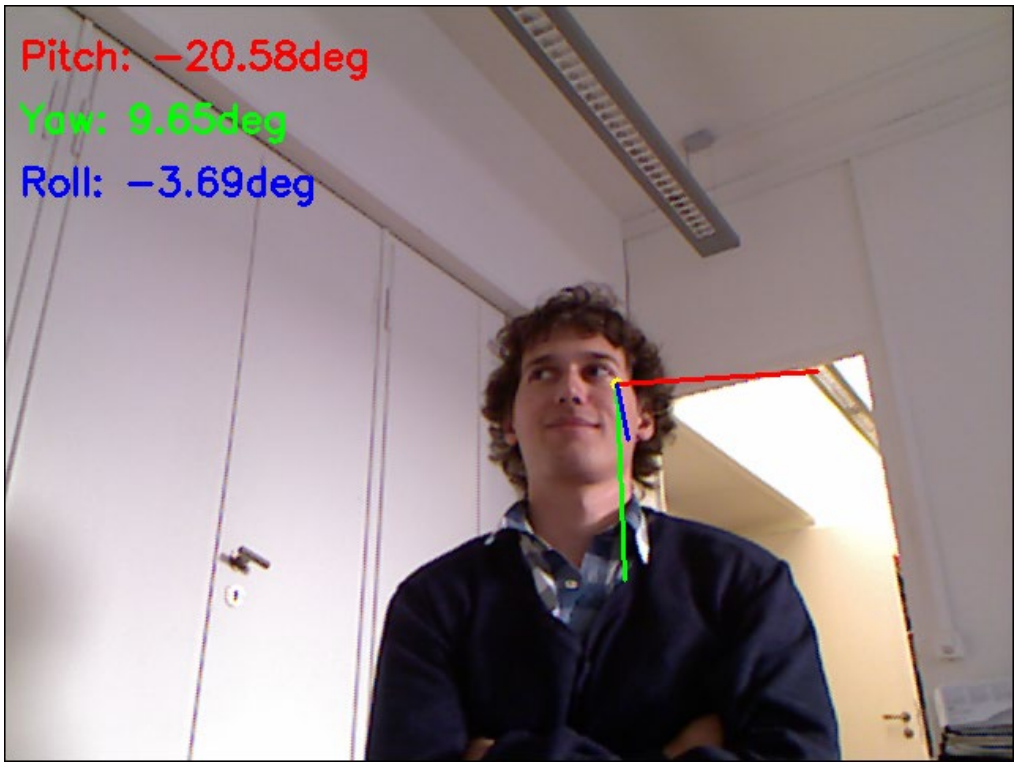
2. HEAD POSE ESTIMATION

2.1. Vizualna interpretacija BIWI Head Pose podataka

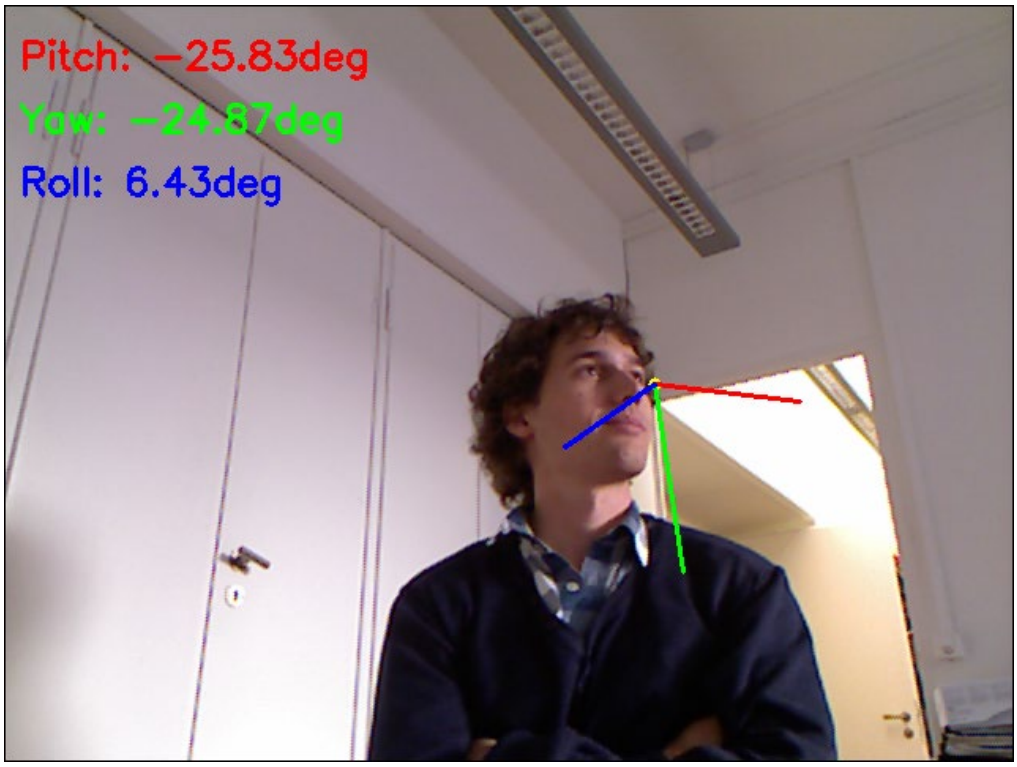
U *framu* "50" *yaw* i *roll* su dobri dok je *pitch* pretjeran i centar je puno pomaknut u lijevo. U *framu* "350" *yaw* i *roll* su dobri dok je *pitch* pretjeran i centar je malo pomaknut ispred glave. U *framu* "508" *yaw* i *roll* su dobri dok je *pitch* pretjeran i centar je pomaknut u lijevo.

Tablica 4. Interpretacija BIWI Head Pose podataka.

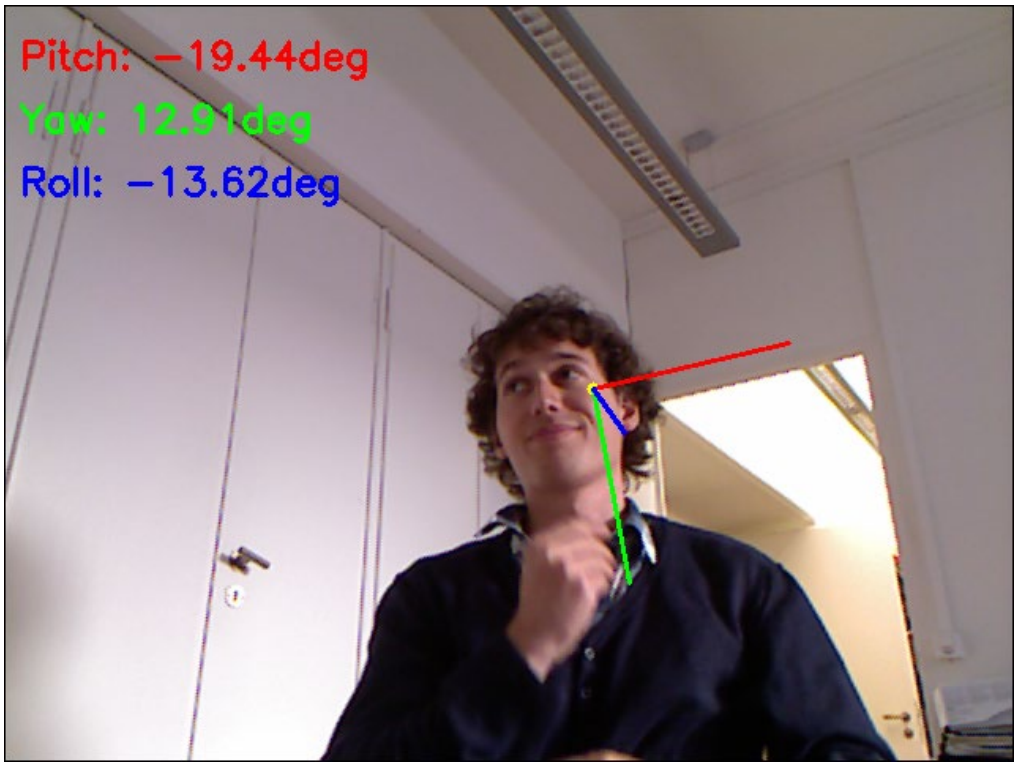
Frame	Pitch (°)	Yaw (°)	Roll (°)	Opis
50	-20.58	9.65	-3.69	Osoba gleda ravno, blago u desno, bez nagiba
350	-25.83	-24.87	6.43	Osoba gleda ravno, u lijevo, bez nagiba
508	-19.44	12.91	-13.62	Osoba gleda ravno, u desno, s nagibom u desno



Slika 4. Interpretacija BIWI Head Pose podataka Frame 50



Slika 5. Interpretacija BIWI Head Pose podataka Frame 350



Slika 6. Interpretacija BIWI Head Pose podataka Frame 508

2.2. Klasifikacija smjera pogleda

Tablica 5. Klasifikacija smjera pogleda

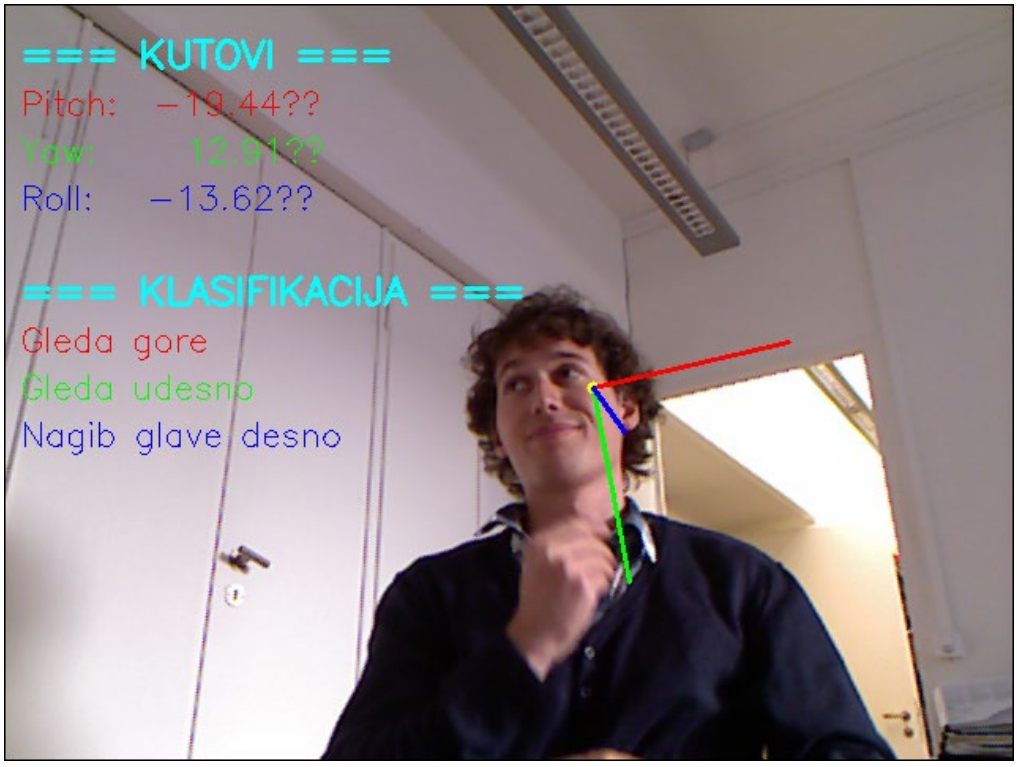
Frame	Pitch (°)	Yaw (°)	Roll (°)	Klasifikacija pogleda (sva tri kuta)
50	-20.58	9.65	-3.69	Gleda gore, Nema nagiba glave, Gleda naprijed
350	-25.83	-24.87	6.43	Gleda gore, Nema nagiba glave, Gleda ulijevo
508	-19.44	12.91	-13.62	Gleda gore, Nagib glave desno, Gleda udesno



Slika 7. Klasifikacija smjera pogleda Frame 50



Slika 8. Klasifikacija smjera pogleda Frame 350

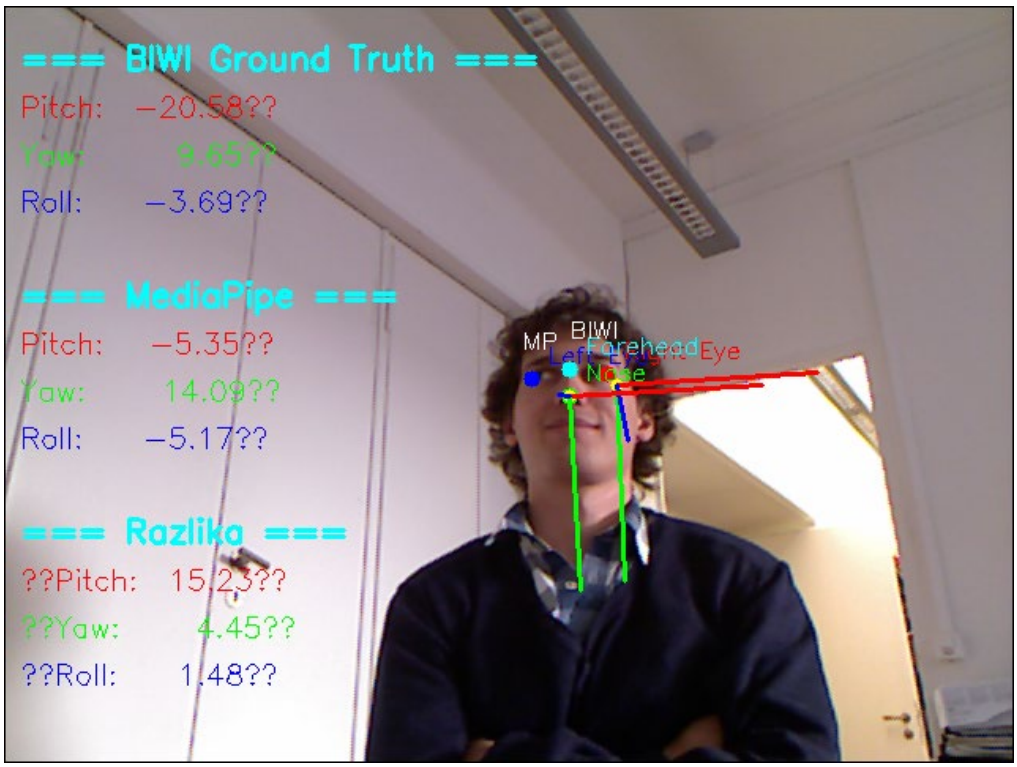


Slika 9. Klasifikacija smjera pogleda Frame 508

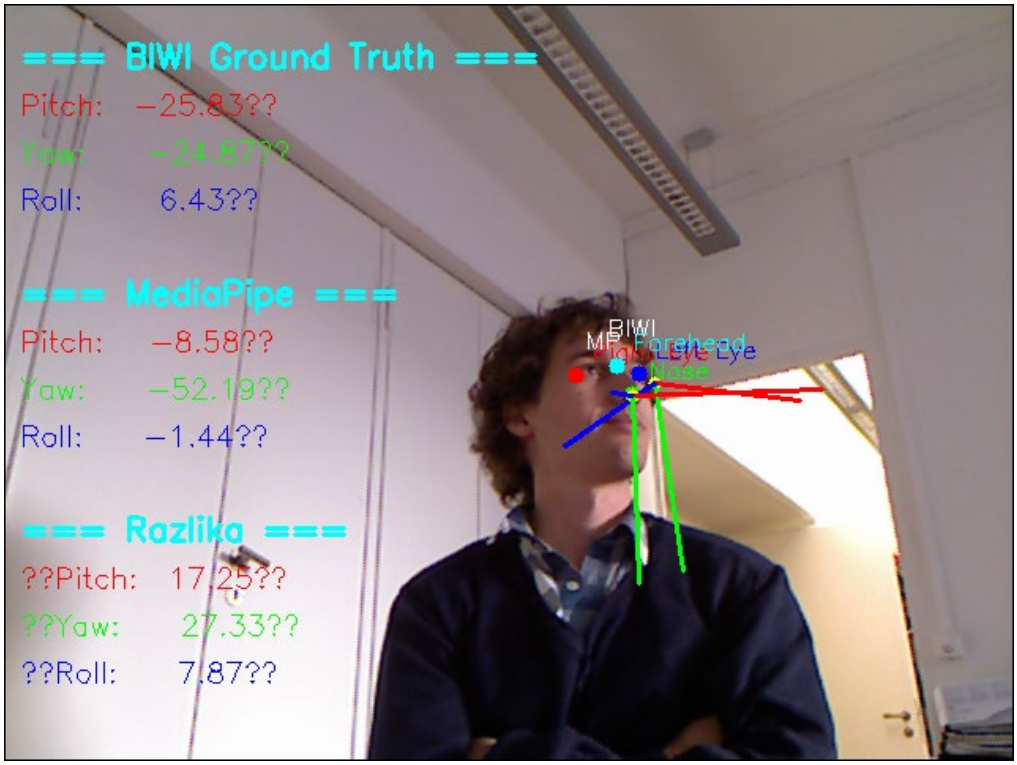
2.3. MediaPipe vs. BIWI: Usporedba orijentacije glave

Tablica 6. MediaPipe vs. BIWI: Usporedba orijentacije glave

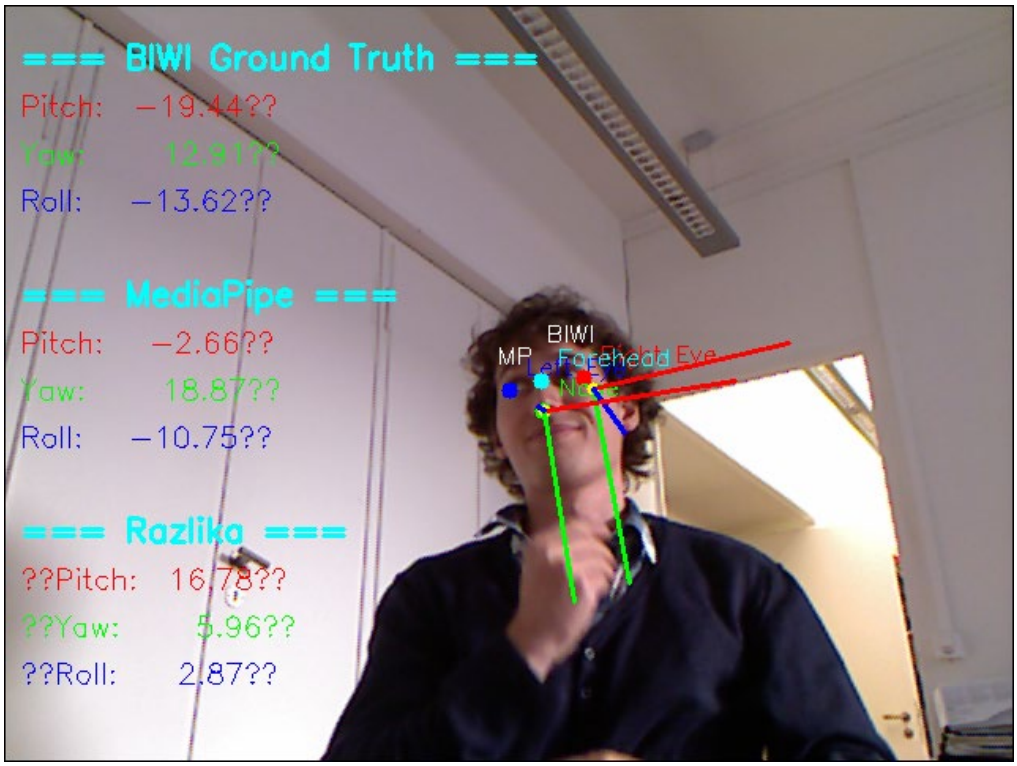
Frame	MP Pitch (°)	BIWI Pitch (°)	MP Yaw (°)	BIWI Yaw (°)	MP Roll (°)	BIWI Roll (°)
50	-5.35	-20.58	15.23	14.09	9.65	4.45
350	-8.58	-25.83	17.25	-52.19	-24.87	27.33
508	-2.66	-19.44	16.78	18.87	12.91	5.96



Slika 10. Usporedba orijentacije glave Frame 50



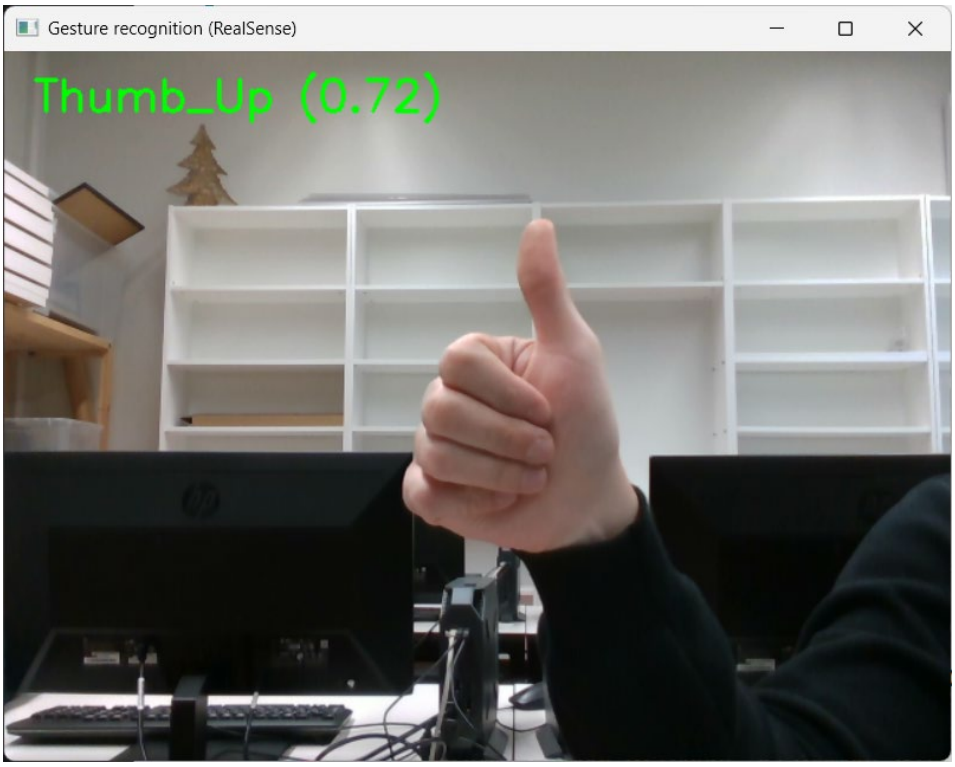
Slika 11. Usporedba orijentacije glave Frame 350



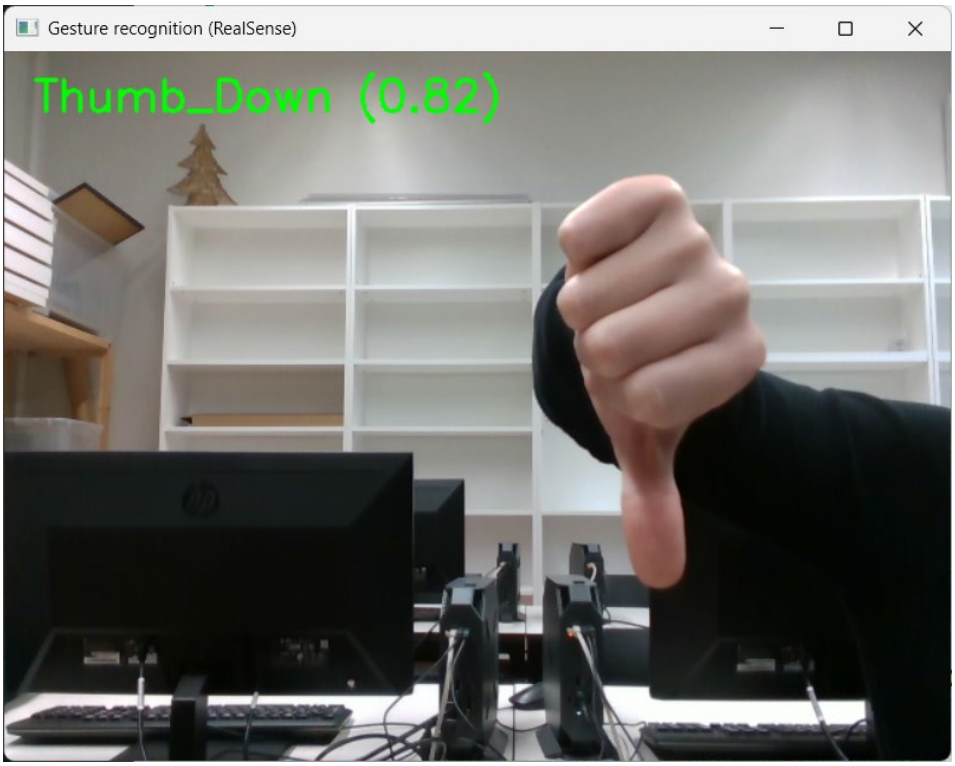
Slika 12. Usporedba orijentacije glave Frame 508

3. GESTURE RECOGNITION

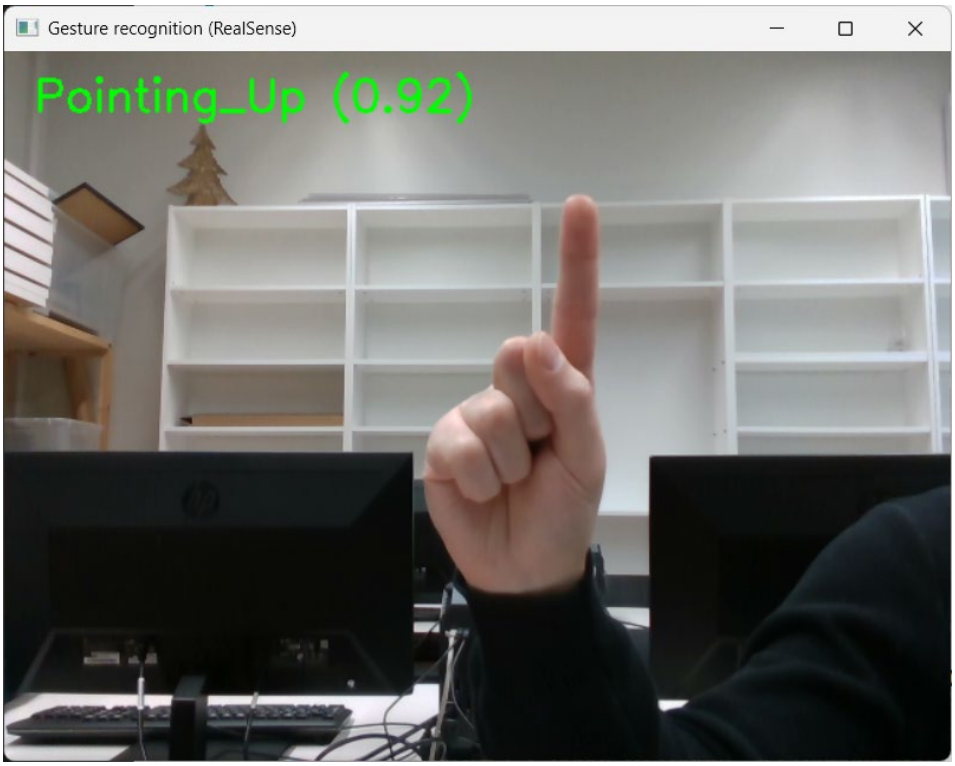
3.1. Gesture Recognition demo



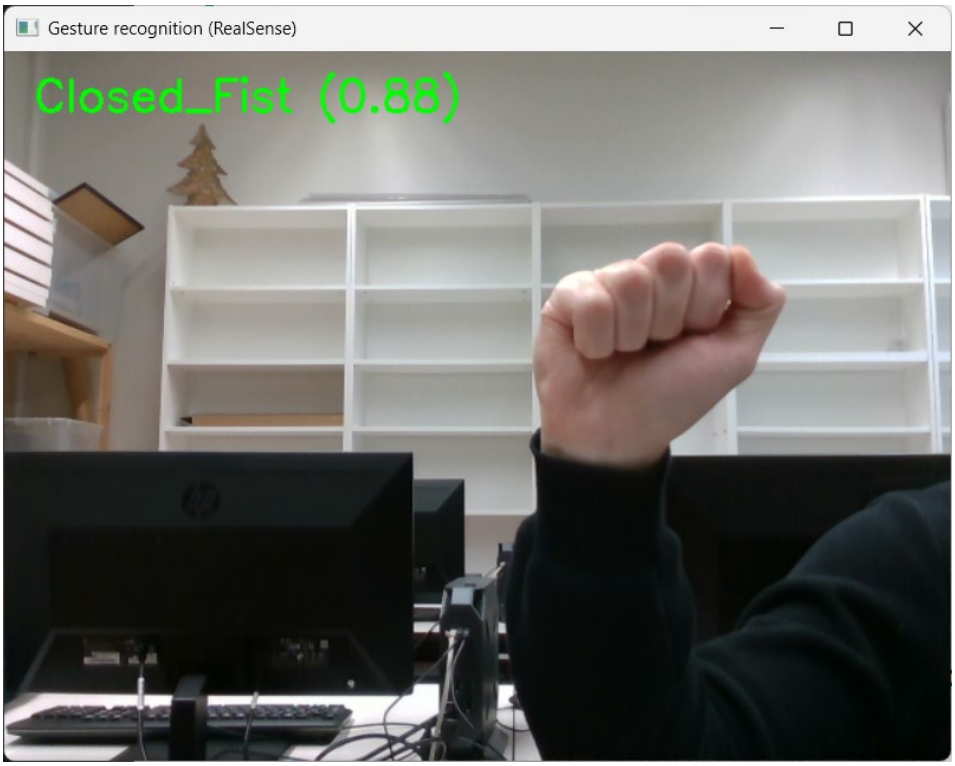
Slika 13. Gesture Recognition demo Thumb up



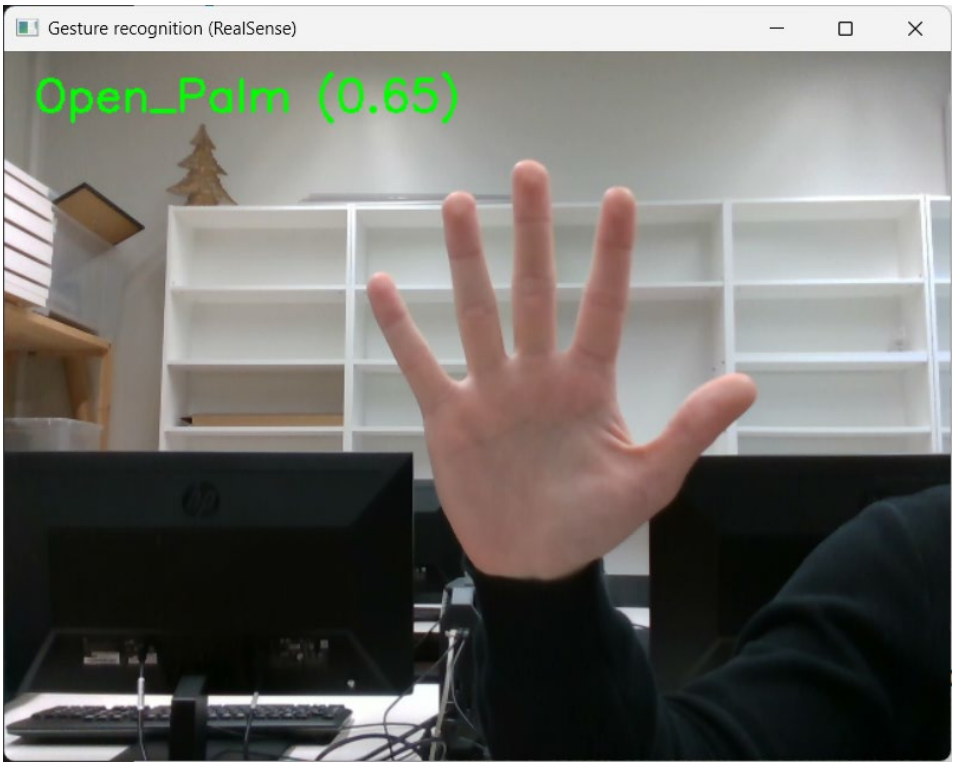
Slika 14. Gesture Recognition demo Thumb down



Slika 15. Gesture Recognition demo Pointing up



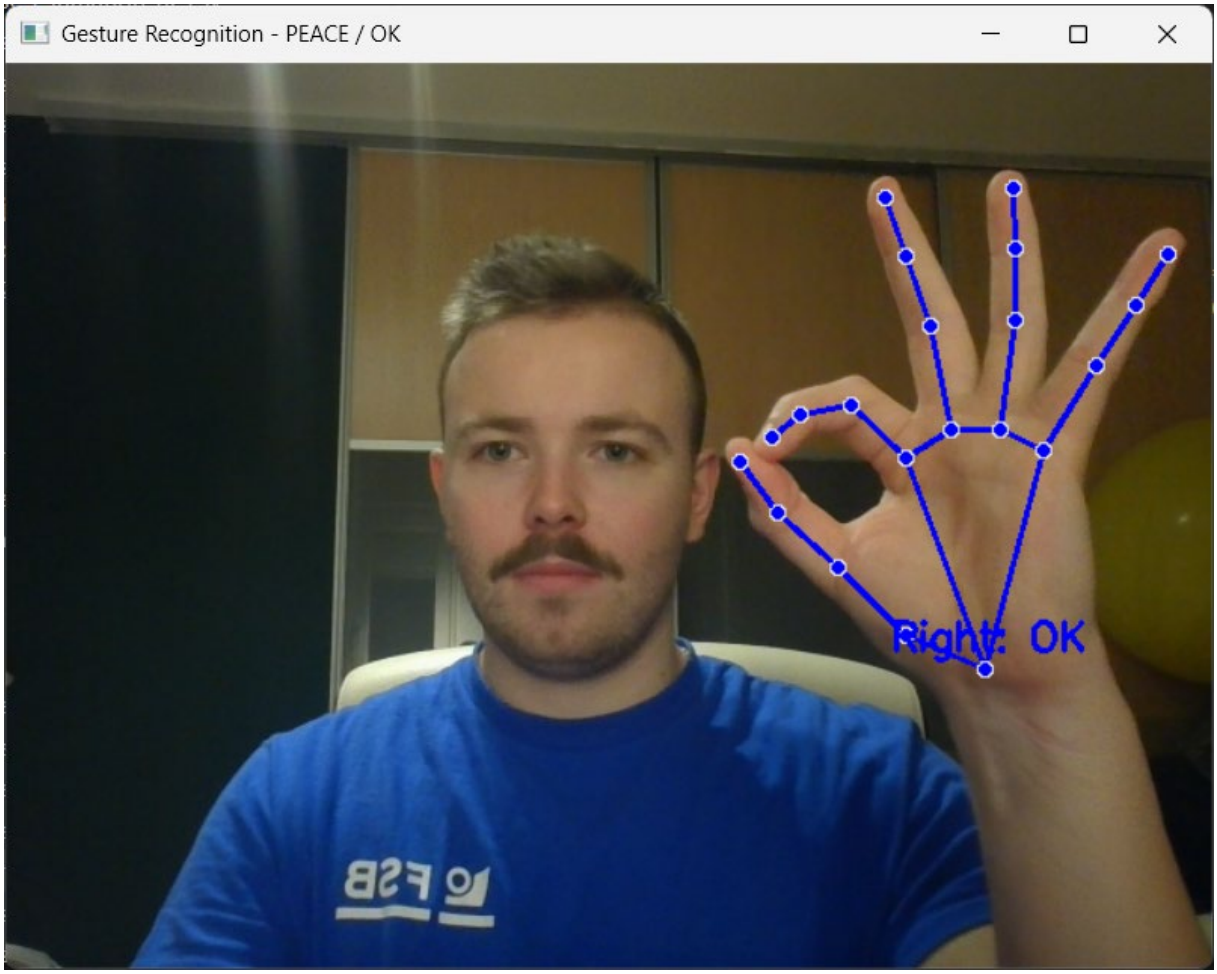
Slika 16. Gesture Recognition demo Closed Fist



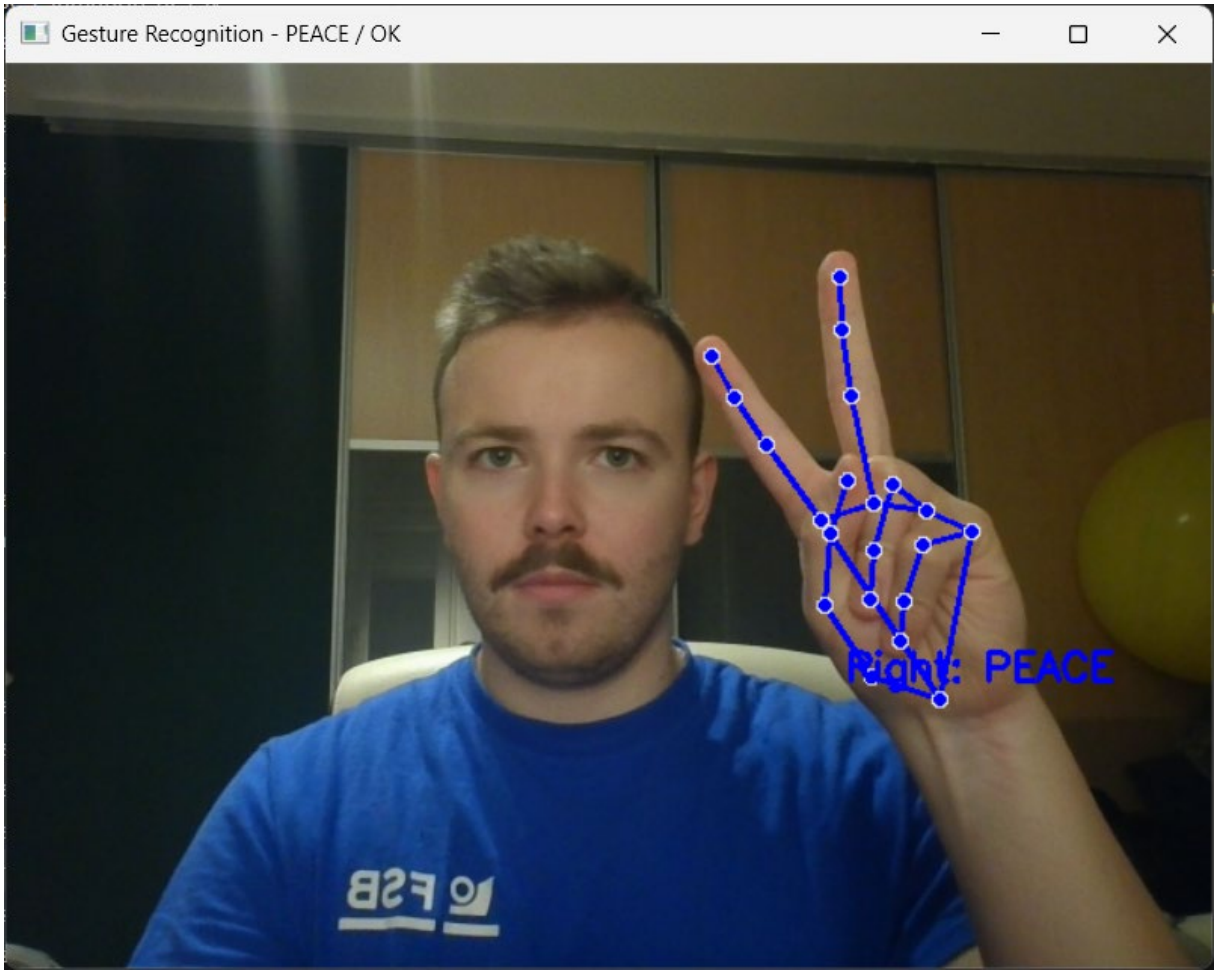
Slika 17. Gesture Recognition demo Open Palm

3.2. Ručno definirana pravila za nove geste

Za PEACE gestu potrebno je da indeks i srednji prst budu ispruženi i međusobno separirani s distancom većom od 0,15 normirane skale ruke, dok palac, prstenjak i mali prst ostaju u zatvorenoj poziciji. Algoritam to provjerava primjenom funkcije *is_finger_open*() koja normalizira distancu svakog prsta od zapešća kako bi se osigurala robusnost na različitim veličinama ruke, što omogućava detekciju geste neovisno o udaljenosti ili veličini ruke u video kadru. Za OK gestu zahtijeva se da palac i kažiprst budu u dodiru s distancom manjom od 0,12 normirane skale, dok su srednji, prstenjak i mali prst ispruženi, što se također provjerava kroz normaliziranu euklidsku distancu između odgovarajućih ključnih točaka.

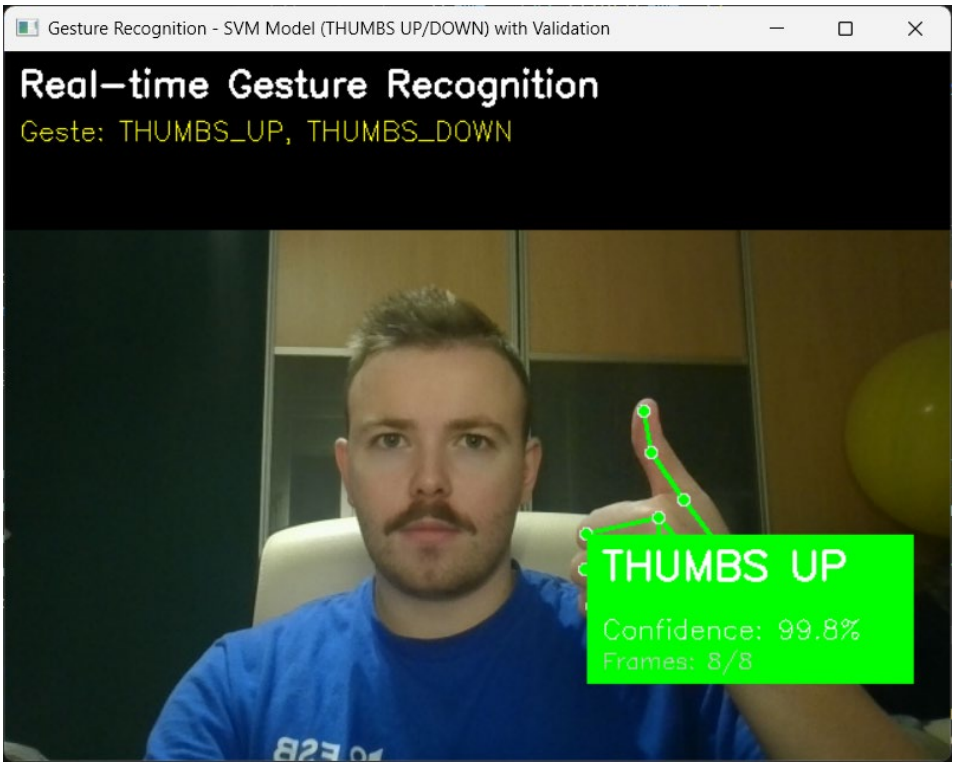


Slika 18. Gesta OK

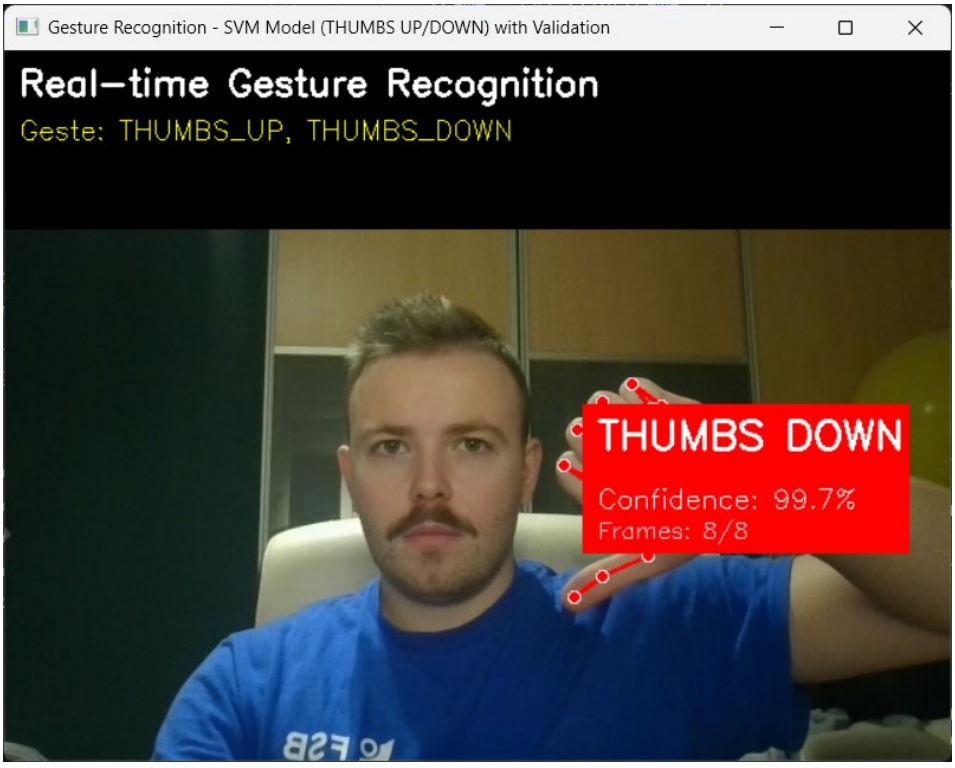


Slika 19. Gesta PEACE

3.3. Klasifikator (ML) za dvije nove geste



Slika 20. Klasifikator gesta THUMBS UP



Slika 21. Klasifikator gesta THUMBS DOWN

PRILOZI

BPE Live tracking i izračun brzine ruke
- body_pose_estimation_04.py

GR Ručno definirana pravila za nove geste
- gesture_recognition_02.py

GR Klasifikator (ML) za dvije nove geste
- 02_train_gesture_model.py
- 03_gesture_recognition_ml.py
- gesture_data.csv

GitHub repozitorij za cijelu zadaću
- https://github.com/KxHartl/interakcija-covjeka-i-robota/tree/main/student_assignment_03